

Classificação de sementes de soja por regras de subgrafos

25 de setembro de 2026

Visão geral

O objetivo é classificar imagens de sementes de soja em 5 classes: Broken, Immature, Intact, Skin-damaged e Spotted. A ideia central é que cada classe tem **arranjos característicos de regiões**, como uma mancha escura encostada numa região clara. O método:

1. **Grafo de cada imagem.** A imagem é segmentada em regiões, e as regiões que se tocam são ligadas.
2. **Duas descrições de cada região.** Uma usa features manuais (visão **full**). A outra usa o embedding de uma rede neural de grafos (visão **GCN**).
3. **Regras em cada visão.** Mineram-se pequenos subgrafos que se repetem, de forma aproximada, só em imagens de treino de uma mesma classe. Cada subgrafo desses vira uma **regra** que vota nessa classe.
4. **Decisão.** Uma imagem nova só recebe classe quando as regras das duas visões votam **na mesma classe**. Nas outras, o classificador se abstém.

Por isso o resultado tem dois números:

- **acerto:** fração correta entre as imagens classificadas;
- **cobertura:** fração das imagens que receberam alguma classe.

Dados. São 5.202 imagens, já sem as 311 duplicatas, divididas em 70/20/10 estratificado: 3.641 de treino, 1.041 de validação e 520 de teste. Rótulos só são usados no treino. A validação escolhe os hiperparâmetros, e o teste é reportado uma única vez.

1. Grafo de regiões de cada imagem

- **Segmentação.** Cada imagem é segmentada pelo algoritmo de Felzenszwalb (scale 300, σ 0,8, min_size 100). Regiões com área abaixo de 0,5% da imagem ou brilho médio abaixo de 0,08 (fundo preto) são descartadas.

- **Grafo.** Cada imagem I vira um grafo $G_I=(V_I, E_I)$: os vértices são as regiões válidas, e E_I liga as regiões que se tocam.
- **Versão aumentada.** Gera-se também uma versão aumentada de cada imagem: recorte, espelhos, rotação de 90° e perturbação de cor. As mesmas transformações são aplicadas ao mapa de regiões, então a região r da aumentada é a mesma região física r da original. A versão aumentada só é usada para treinar a GCN (Seção 3). As regras usam apenas as imagens originais.





Imagem 987 (Broken): imagem, segmentação (14 regiões válidas numeradas; descartadas em cinza) e grafo de regiões com 25 arestas.



Versão aumentada da 987: recorte, espelho, rotação de 270° e cor. A segmentação não é refeita: os números das regiões batem com os da original.

2. Visão full: features manuais

Cada região v é descrita por um vetor $x_v \in R^{344}$ calculado só com os pixels dela:

- **cor:** momentos em L^*a*b^* , matiz e saturação;
- **textura:** LBP e MCLBP multicanal, gradiente e GLCM;
- **forma e posição:** área, perímetro, circularidade, excentricidade, distância ao centro da semente etc.

Cada feature é padronizada por z-score. Nenhum rótulo é usado.

3. Visão GCN: embedding aprendido

Todas as regiões de todas as imagens, originais e aumentadas, formam um único grafo com 77.643 vértices e as arestas de adjacência da Seção 1. Nesse grafo, uma GCN de duas camadas com atalho linear, sobre as features 1×1 (92 dimensões), produz um vetor $z_v \in R^5$ para cada região:

$$Z = \hat{A}(\hat{A}XW_1 + b_1)W_2 + b_2 + 0,3(XW_0 + b_0), \hat{A} = \tilde{D}^{-1/2}(A + I)\tilde{D}^{-1/2}$$

Treino. A GCN é treinada com perdas de ranqueamento de pares sobre triplets (âncora i , positivo p , negativo n):

$$\ell(i, p, n; \mu) = \max(0, \mu - [\langle z_i, z_p \rangle - \langle z_i, z_n \rangle]), L = w_{ssl}L_{ssl} + w_{rank}L_{rank} + w_{comm}L_{comm}$$

A perda é relativa: o positivo só precisa ser mais similar à âncora que o negativo, por uma folga μ .

- L_{ssl} : aproxima cada região aumentada da sua região original. O negativo é uma região de outra imagem. Não usa rótulos.
- L_{rank} : aproxima regiões de treino de **imagens diferentes** da mesma classe. O negativo é uma região de treino de outra classe.
- L_{comm} : afasta pares de regiões de treino de classes diferentes que o embedding ainda confunde. Periodicamente, o grafo é reconstruído com os pares de embeddings mais similares, e dele se extraem comunidades por propagação de rótulos. Os pares de treino de classes diferentes que caem na mesma comunidade viram negativos difíceis.

Seleção do checkpoint e hiperparâmetros. O treino é interrompido quando o agrupamento obtido nessas comunidades deixa de melhorar na validação. O checkpoint salvo é o do melhor ponto. Os hiperparâmetros da GCN são os da configuração #57, escolhida numa busca anterior com critério próprio.

Detalhes da configuração #57. Taxa de aprendizado 0,0026 e decaimento de peso 0,0015 (Adam); margens $\mu_{ssl} = 0,16$, $\mu_{rank} = 0,52$ e $\mu_{comm} = 0,90$; pesos $w_{ssl} = 1,20$, $w_{rank} = 0,99$ e $w_{comm} = 0,49$; 1.024 triplets de cada perda por época; rebuild a cada 200 épocas com os 99.160 pares mais similares; no máximo 25 rebuilds. O agrupamento na validação é medido pelas comunidades 100% puras no treino (pelo menos 2 imagens de treino, todas da mesma classe): acerto e cobertura delas na validação, resumidos pela média harmônica (F). O treino roda pelo menos 5 rebuilds e para após 3 rebuilds seguidos sem melhora; fica o checkpoint do melhor ponto.

Sem vazamento. Em cada partição dos dados, a GCN é treinada do zero usando **apenas os rótulos de treino** daquela partição.

Como o embedding se forma

A figura acompanha quatro grafos de imagem durante o treino:

- a 987 original;
- a 987 aumentada;
- a 64, da mesma classe (Broken);
- a 134, de outra classe (Spotted).

Cada painel desenha os grafos com um layout de força ancorado no embedding:

$$\sum_{(i,j) \in E} (\|x_i - x_j\| - L)^2 + \sum_{i < j} \frac{c}{\|x_i - x_j\|} + \lambda \sum_i \|x_i - r_i\|^2$$

As arestas são as de adjacência, e a âncora r_i é a posição da região no espaço dos embeddings (MDS do cosseno), com $\lambda=3$. Regiões com embeddings parecidos ficam próximas, e as arestas mantêm cada grafo legível.



Os quatro grafos ao longo do treino. Círculos: 987 original; triângulos: 987 aumentada; quadrados: 64 (mesma classe); losangos: 134 (outra classe). Traços finos: arestas de adjacência. Tracejado: liga cada região da 987 original à mesma região da aumentada (par da L_{ssl}). “cos par” é o cosseno médio desses pares; “correto” conta quantas regiões têm a própria cópia como vizinha mais próxima.

Cosseno médio	Features	Ép. 0	Ép. 300	Ép. 1000 (checkpoint)	Ép. 1600
Orig.–aum.	0,41	0,35	0,74	0,79	0,80

Cosseno médio	Features	Ép. 0	Ép. 300	Ép. 1000 (checkpoint)	Ép. 1600
Mesma classe	0,15	0,10	0,30	0,34	0,36
Outra classe	0,13	0,06	-0,05	-0,07	-0,04

Cosseno médio global, medido em todas as imagens. *Orig.-aum.* é o alvo da L_{ssl} , e *Mesma classe* é o alvo da L_{rank} .

Leitura:

- A região aumentada se funde à original: o cosseno sobe de 0,35 para 0,79.
- Regiões da mesma classe se aproximam: $0,10 \rightarrow 0,34$. Regiões de classes diferentes se afastam: $0,06 \rightarrow -0,07$.
- Nas épocas finais, a 64 encosta no bloco da 987, e a 134 fica à parte.

É esse espaço, em que “parecido” já inclui “da mesma classe”, que a visão GCN usa para comparar regiões.

4. Regras de subgrafos (em cada visão)

O mesmo procedimento roda separadamente na visão full (x_v) e na visão GCN (z_v), só com as regiões das imagens originais.

Candidatos. Para cada região v e cada outra imagem I , os candidatos são as regiões de I entre as K mais parecidas com v , com similaridade de pelo menos τ :

$$cand_{\tau}(v, I) = \{u \in kNN_K(v) \cap V_I : \cos(v, u) \geq \tau\}$$

No espaço da GCN, com só 5 dimensões, os cossenos entre vizinhos são muito altos: até o 200º vizinho passa de 0,88. Por isso o limiar da GCN é buscado numa faixa própria, de 0,85 a 0,999.

Padrão e ocorrência. Um padrão P é um subgrafo conexo do grafo de uma imagem de treino. P **ocorre** numa imagem I se existe um mapeamento injetivo φ que leva cada região de P a um candidato em I e preserva as adjacências:

$$\varphi(p) \in cand_{\tau}(p, I) \forall p \in P, (p, q) \in E_P \Rightarrow (\varphi(p), \varphi(q)) \in E_I$$

O **suporte** $\sigma(P)$ é o número de imagens de treino em que P ocorre.

Ocorrência na imagem de origem. Os candidatos são definidos para as outras imagens; na imagem de onde o padrão foi tirado, ele sempre ocorre (cada região mapeada nela mesma). Por isso, a imagem de origem entra no suporte.

Mineração. O suporte é anti-monótono: um padrão maior nunca ocorre em mais imagens que um padrão menor contido nele. Então a mineração segue o esquema Apriori por níveis:

- começa com padrões de 1 região;
- estende cada padrão por uma região vizinha na imagem de origem, estendendo junto as ocorrências;
- mantém o padrão enquanto $\sigma \geq \sigma_{min}$.

Não há limite de tamanho. Guardam-se no máximo M mapeamentos por imagem.

Salvaguarda. Mesmo sem limite de tamanho, alguns parâmetros (limiar baixo, suporte mínimo 1) podem fazer o número de padrões explodir. Se um nível da mineração passar de 2 milhões de padrões, a configuração é descartada na busca, em vez de seguir com os padrões cortados. Assim, todo resultado reportado foi minerado sem corte; na busca, a trava nunca disparou.

Regras e voto. Um padrão vira **regra da classe** c quando ocorre em pelo menos m imagens de treino e **todas** elas são da classe c . Cada regra vota em c em toda imagem de validação ou teste em que ocorre, e a visão prediz a classe mais votada.

Empate no voto. Se duas classes empatam em número de votos, a visão fica com a primeira delas na ordem em que os votos foram contados.

5. Decisão: as duas visões concordam

$$\hat{y}_I = \{\hat{y}_I^{full}, \text{ se as duas visões votaram e } \hat{y}_I^{full} = \hat{y}_I^{GCN} \text{ sem resposta, caso contrário}$$

As duas visões comparam regiões com régua diferentes:

- a full usa aparência bruta;
- a GCN usa um espaço aprendido com os rótulos de treino, que também carrega informação da vizinhança.

Quando as duas chegam à mesma classe, a chance de erro cai.

Full e GCN votam na mesma classe → predição: Spotted (correta)

Visão full (features manuais): padrão de 4 regiões
imagem de treino 110 (Spotted); aparece em 5 imagens de treino, todas Spotted
→ regra 'Spotted'





Imagem de teste 362 (classe real: Spotted)
mesmo padrão encontrado (regiões 1-4 correspondentes)
193 regras votaram Spotted nesta visão



Visão GCN (embedding): padrão de 5 regiões
imagem de treino 154 (Spotted); aparece em 1 imagem de treino
→ regra 'Spotted'





Imagem de teste 362 (classe real: Spotted)
mesmo padrão encontrado (regiões 1-5 correspondentes)
248 regras votaram Spotted nesta visão



Uma regra de cada visão aplicada à imagem de teste 362 (Spotted). À esquerda, o padrão na imagem de treino de origem; à direita, o mesmo padrão encontrado na imagem de teste. Regiões correspondentes têm a mesma cor e o mesmo número, e os traços são as adjacências do padrão. As duas visões votam Spotted, então a predição é Spotted (correta).

6. Hiperparâmetros e resultado

Os parâmetros das regras foram escolhidos por busca automática (Optuna, amostrador TPE), só na validação. O objetivo foi a maior cobertura com acerto de pelo menos 90%. A melhor configuração:

Parâmetro	Valor
vizinhos considerados (K)	188
mapeamentos guardados por imagem (M)	8
suporte mínimo para crescer (σ_{min})	1
limiar de similaridade da full (τ_{full})	0,67
imagens de treino mínimas para votar, full (m_{full})	2
limiar de similaridade da GCN (τ_{GCN})	0,94
imagens de treino mínimas para votar, GCN (m_{GCN})	1

	Acerto	Cobertura
Validação	89,8%	67,6%
Teste	86,6%	64,6%

O classificador responde para cerca de 2 em cada 3 imagens e, no teste, acerta cerca de 87% das que responde. A mineração leva cerca de 2,5 minutos na visão full e 5 minutos na visão GCN.

7. Limitações e próximos passos

- **GCN não otimizada para este uso.** Os hiperparâmetros da GCN foram escolhidos para outro critério (agrupamento em comunidades), e não para servir de visão das regras. Ajustá-los para as regras pode melhorar o resultado.